


ASKNDER NADA



النهج
IDSS

2025

K Means

- **Unsupervised learning** is a type of machine learning that learns from **test data** that **has not been labeled**, classified or categorized.

ببقي عنده داتا بيفهمها بس الداتا دي مش بتبقي label يعني مثلا هو ممكن يحط كذا معلومة مع بعض متفقين في صفات معينة بس من غير ما يقولك المجموعة دي كلها علي بعض اسمها ايه .. يعني ممكن احط فواكهه مع بعض لمجرد انها مشتركة في صفة انها فاكهه بس مش هقولك ان دي فاكهه .. هقولك بس ان الوانها زي بعض .. طبيعة زرعها زي بعض و هكذا

- **In supervised learning** is the learning algorithm is just shown **the input data** and asked to extract knowledge from this data **has been labeled**

هنا بقا العكس بياخد ال input داتا اللي داخله و بيفهمها و بيبدء يستخرج منها المعرفة علشان يعرف يطلعك مسمي مناسب للداتا دي

➤ **There are many kinds of unsupervised learning such as:**


- **Clustering.**

- Clustering is grouping the data instances into predetermined number of groups **based on the similarity between these instances.**

بحط اي داتا فيها شبه من بعض

- **Anomaly Detection.**

- **(or outlier detection)** is the identification of the rare **or unusual items**, events or observations which raise suspicions by differing significantly from the majority of the data.




الداتا بتبقي كلها نفس الرينج و نفس كل حاجة بس تلاقي معلومة عاقة كذا طلعت برا الرينج دا

- **Association rules.**

- Association rules refers to the process to **find the association between features' values** in the data set to make decision based on these rules later.

دي اني احاول اوصل لعلاقة ما بين معلومة و معلومة .. زي مثلا كارفور لما بتحط سيكشن السكر جنب سيكشن الشاي لانه لقوا علاقة في الداتا عندهم ان كل اللي بيشترى سكر بيروح بعدها يشتري شاي



تعالى اشرحك الرسمة : بص ي صاحبي انا دلوقتي عندي مجموعة درجات عملت بيها مجموعتين . مجموعة للي نجحوا و مجموع لي سقطوا .. ف دلوقتي الفروق اللي هتبقى جوا المجموعة ذات نفسها هتبقى كبيره ولا صغيرة؟ لا اكيد هتبقى صغيره لانهم متشابهين و جوا مجموعة واحدة سواء نجحوا او سقطوا


طب الفروق ما بين المجموعة و المجموعة هيبقي كبير ولا صغير؟ لا هيبقي كبير لان دي مجموعة ناجحة و دي مجموعة سقطة

➤ Types of Clusterings

• Partitional Clustering (non-overlapping subsets)

- A division of data objects into **non-overlapping subsets** (clusters)


ببقي اثنين كلاستر ملهمش علاقة ببعض (non overlapping) مش متصلين ببعض يعني



• Hierarchical clustering (overlapping subsets)

- A set of **nested clusters** organized as a hierarchical tree


ببقي كلاسترز جوا بعض .. واحدة كبير و جواها اصغر ف اصغر



➤ Classification


- **Have labels** for some points
- Want a **"rule"** that will accurately assign labels to new points
- **Supervised learning**

زي ما شرحتهك فوق يا صديقي ان ال supervised فوق ان ببقي فيها مسمي .. و اكيد انت مش هستمي عبط كدا لا اكيد هبقي في rule لل label دا



➤ Clustering

- **No labels**
- Group points into clusters based **on similarity**
- how **"near"** they are to one another
- Identify **structure in data**
- **Unsupervised learning**



هنا انا مش بخطط مسمي بهتم بس اني احط الحاجات اللي شبه بعض مع بعض في جروب واحد و بشوف مدى قرب المعلومات جوا المجموعة او قريها لمجموعة تاني

➤ **k-means clustering** is one of the simplest and most commonly used clustering algorithms.

- It tries to find cluster centers that are representative of certain regions of the data.
- **The algorithm alternates between two steps:**
 - Assigning each data point to the closest cluster center, and then setting each cluster center as the mean of the data points that are assigned to it.
 - A distance metric or function is used to assign the point to the closest center.
 - Euclidian distance or Manhattan distance, among others: Jaccard, Spearman, Hamming, and Cosin
 - The algorithm is finished when the assignment of instances to clusters no longer changes

الكلام دا هتفهمه لما تيجي تحل عملي بأيدك بس تعالي كدا احكيك قصته سريعا .. دلوقتي انا عندي طريقه احسن بيها الفرق ما بين الكلاستر و الكلاستر و الطريقة دا اسمها k means ال K بتشير لل center بتاع الكلاستر (اللي هو النقطة اللي في نص الكلاستر) و means بتشير انك هتسب المتوسط

ف انت هتعمل خطوتين .. اول خطوة هتختار اي نقطتين انت عايزهم ي صاحبي و بعد كدا هتشاف باقي النقط هتبيقي قريبة من انهي نقطه و تحطهم كلهم في كلاستر واحدة بعد كدا بتسب عليهم المتوسط.. مش فاهم صح؟ هشرحك عملي حالا والله

بس خليك عارف الطريقه اللي شرحتهالك دي علشان بس تعمل assign لكل حاجة شبه بعض فيه كلاستر واحدة و لو عايز تجيب المسافة ما بينهم بقا هتستخدم طريقه من الاثنين يا Manhattan distance يا Euclidian distance و علشان تعرف انك وصلت للحل النهائي خلاص هتلاقي ان في نقطتين هيطلعوا بنفس المسافة ورا بعض ف هتعرف ن كدا الكلاستر no longer changes


يلا بينا نفهم عملي بق

Example one

Given: {2,4,10,12,3,20,30,11,25}, k=2

زي ما قولتلك يا صاحبي اختار اي نقطتين انت عايزهم مثلا هختار ال $c_1=4$ $c_2=3$

هبدء اشوف باقي الارقام بقا قريبين من انهي نقطة من النقطتين اللي انا اختارتهم...



هبدء اجيب ال means ليهم (المتوسط) بتاع كل كلاستر و دا بيتحسب اني بجيب مجموع كل الارقام دي علي عددهم

- $C_1 = (4+10+12+20+30+11+25) / 7 = 16$
- $C_2 = (2+3) / 2 = 2.5$

هاخد ال النقطتين دول اللي هما 2.5 و ال 16 و هعمل بيهم نفس الحاجة هبدء اكون 2 كلاسترز و اشوف مين الارقام القريبة من دا و الارقام القريبة من دا و هسحبهم ليهم ال Means لاحظ ما الاقي ان ال mean بتاعي ثبت يعني ايه ثبت يعني ال mean اللي حاسبته عند النقط دي بقا هو هو ال mean اللي حاسبته في المرة اللي قبلها

Given: {2,4,10,12,3,20,30,11,25}, k=2

- Randomly assign two centers: $C_1=3, C_2=4$
- $K_1=\{2,3\}, K_2=\{4,10,12,20,30,11,25\}, C_1=2.5, C_2=16$
- $K_1=\{2,3,4\}, K_2=\{10,12,20,30,11,25\}, C_1=3, C_2=18$
- $K_1=\{2,3,4,10\}, K_2=\{12,20,30,11,25\}, C_1=4.75, C_2=19.6$
- $K_1=\{2,3,4,10,11,12\}, K_2=\{20,30,25\}, C_1=7, C_2=25$
- $K_1=\{2,3,4,10,11,12\}, K_2=\{20,30,25\}, C_1=7, C_2=25$

Stop as the clusters with these means are the same.

و خليك فاكر يا صاحبي لو طلب منك انك تجيب ال Distance بأي طريقة من الطريقتين استخدم القوانين دي

How to Calculate Distance

1- Euclidian Distance =

$$\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

2- Manhattan Distance =

$$|x_1 - x_2| + |y_1 - y_2|$$